

基於數位雙生與視覺語言世界 模型之具身智能控制系統

姓名：陳品君

日期：**2026/6/8 ~ 2026/6/14**

一、研究背景與核心痛點

實體數據採集的痛點：

- 在實體環境中採集機器人數據成本高昂且具危險性，缺乏實體手臂時無法大規模收集不撞毀環境的專家軌跡。

解決方案：Isaac Sim 數位雙生與世界模型：

- 本專案旨在建立一個精準的 **NVIDIA Isaac Sim** 數位雙生場景，手動校準並賦予自建 **3D** 物件精確的物理特性（如質量、摩擦力、剛性），解決幾何與物理邊界未貼合的缺陷。
- 將此高品質模擬資料打包，透過 **V-JEPA 2** 結合大語言模型 (LLM) 進行多模態混訓。
- 終極目標：讓機器人同時聽懂「文字指令」與看懂「影片時序」，賦予其高效率的空間預測與規劃能力（**Prediction & Planning**）。

二、系統架構與資料流 (System Architecture)

階段一：Isaac Sim 高精度數位雙生建置 (Digital Twin Layout)

- 自建 3D 物件資產匯入 → 在 Isaac Sim 中進行網格優化（解決未貼合問題） → 標定真實物理屬性（密度、材質阻尼）。

階段二：自動化高純度數據採集 (Data Factory)



- 運行 xArm 運動控制（整合逆運動學 IK 與防發抖過濾） → 自動隨機 Spawn 物體 → 產出 4 FPS、256 X 256 解析度的時序影像與動作標籤 → 打包為 RLDS 標準資料集。

階段三：V-JEPA 2 + LLM 多模態混訓 (MLLM Alignment)

- 透過 MLP 投影層將 V-JEPA 2 視訊編碼器特徵對齊 Llama 3.1 語言核心 → 實現能聽懂指令、看懂視訊物理因果的具身大腦。


三、本週進度與技術除錯 (Current Progress & Debug)

模擬硬體成功遷移：成功在 Isaac Sim 中導入並跑通 uFactory xArm 機械臂手模型（取代先前的 Franka機械手臂）。



三、本週進度與技術除錯 (Current Progress & Debug)

閉環夾取功能驗證：成功實現手臂對目標紅方塊的精準閉合與夾取動作



三、本週進度與技術除錯 (Current Progress & Debug)

定位關鍵技術障礙（模型未貼合）：

- 現象：自建模型的外觀視覺網格（Visual Mesh）與物理碰撞網格（Collision Mesh）存在位移，導致抓取時產生非線性滑移。
- 本週對策：嘗試在 Isaac Sim 中手動/腳本校準，採用網格凸包分解（Convex Decomposition）重新修正幾何邊界，確保物理碰撞與視覺完全貼合。



四、核心訓練機制：V-JEPA 2 多模態對齊

為了讓模型同時聽懂文字指令並看懂影片時序，我們規劃對齊 Meta 論文的三階段漸進式的對齊管線：

- Stage 1: 投影層線性對齊 (Projector Alignment)
 - 凍結 V-JEPA 2 與 LLM，僅訓練中間的 MLP 投影層，建立基礎「圖文空間映射」。
- Stage 2: 大規模多模態問答 (Image-Text QA)
 - 解凍大語言模型（LLM），引入高品質問答數據，利用語言常識激活模型對 3D 空間關係與物體屬性的語義推理能力。
- Stage 3: 影片時序指令微調 (Video SFT)
 - 餵入連續影片幀，結合 Perception Test 與 TempCompass 等時序問答集，讓模型結合 V-JEPA 2 的世界預測能力，學會真正的物理動態與文字因果關係（如：繞過柱子夾取）。

六、期程與開發規劃 (Project Timeline)

階段	預估時程	核心工作內容	預期交付成果
Phase 1: 幾何與物理校準	2026/6/8 ~ 2026/6/14	在 Isaac Sim 解決 xArm 與 3D 物件碰撞模型未貼合問題；實作網格重構。	100% 貼合且物理參數精確的模擬場景
Phase 2: 數據大規模生成	2026/6/14 ~ 2026/6/17	動態 Spawn 各類自建 3D 物品；自動錄製 4 FPS 規格之時序影像與動作 JSON。	500+ 組高純度無發抖專家資料集 (RLDS)
Phase 3: 多模態大腦混訓	2026/6/17 ~ 2026/6/22	使用 LLaVA-NeXT / Lingua 框架，將 V-JEPA 2 視覺特徵與 Llama 3.1 語言特徵對齊。	聽得懂指令、看得懂影片的核心模型
Phase 4: 閉環控制驗收	2026/6/22	移除腳本，由 V-JEPA 2 多模態大腦完全閉環接管 xArm 控制，進行零樣本泛化測試。	零樣本泛化夾取驗收影片

五、參考資料 (References)

- **V-JEPA 2 (視覺世界模型核心)** <https://arxiv.org/abs/2506.09985>
 - 文獻：Assran, M., Bardes, A., Fan, D., Garrido, Q., Howes, R., Komeili, M., ... & Ballas, N. (2025). **V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning**. *arXiv preprint arXiv:2506.09985*.
 - 重要性：專案的視覺主幹，提供強大的時序動態與物理歸納偏置（Inductive Bias），在潛在表徵空間進行高效率動作規劃。
- **LLaVA-NeXT (多模態圖文/視訊對齊框架)** <https://arxiv.org/abs/2407.07895>
 - 文獻：Liu, H., Li, C., Li, Y., & Lee, Y. J. (2024). **Improved baselines with visual instruction tuning (LLaVA-NeXT)**. *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
 - 重要性：定義了非代幣化早期融合（Non-tokenized Early Fusion）管線與中間的 MLP Projector 映射機制，是將 V-JEPA 2 權重與 LLM 對齊的底層程式庫生態。
- **Llama 3.1 (語言核心與動作序列輸出)** <https://arxiv.org/abs/2407.21783>
 - 文獻：Dubey, A., Jauhri, A., Pandey, A., Raghavan, A., Bhargava, A., Cao, R., ... & Meta Llama Team. (2024). **The Llama 3 Herd of Models**. *arXiv preprint arXiv:2407.21783*.
 - 重要性：本系統的語義大腦，接收投影後的時序視覺代幣（Visual Tokens），輸出自然語言推理或 xArm 機械手臂的 7D/11D 動作序列。



THANK YOU